

基于深度学习模型的月球矿物绘图仪（M³）高光 谱数据去噪

摘要：月球矿物绘图仪（M³）高光谱数据是月表矿物识别与地质演化研究的核心支撑，但其受条带噪声干扰严重，空间与光谱域特征失真，直接制约矿物反演结果和后续研究，因此开展适配 M³ 数据特性的去噪研究具有重要的科学与应用价值。现有高光谱去噪方法多面向地球场景，对月球极端环境下的噪声特性适配性不足，深度学习方法则面临真实训练样本稀缺、真实噪声泛化能力弱的瓶颈。本文以构建适配月球 M³ 数据的高效可靠深度学习去噪方案为目标，基于 LRHP 模型构建样本数据集，同时依据实测数据统计建立贴合月球真实特征的混合噪声模型，以此完成训练数据集的搭建，并在此基础上在稀疏、中等、密集三类噪声情况下对比测试 5 种深度学习去噪模型。结果表明，本文构建的噪声模型更贴合 M³ 真实噪声分布，LAMamba 模型在三类噪声场景下综合评分分别达 0.4869、0.4783、0.6247，整体性能最优，光谱角 SAM 最低可达 0.0086，可有效抑制噪声并保留矿物光谱特征，深度学习模型能在样本数据集的基础上，进一步挖掘空间与光谱特征，达到优于传统方法的去噪效果。研究成果可为月表矿物反演与地质特征分析提供可靠的方法与数据支撑。

关键字：月球矿物绘图仪（M³）、高光谱去噪、深度学习、条带噪声

1 引言

随着深空探测技术的快速发展，月球的地质演化、矿物资源分布研究成为航天领域的重要方向。2008 年月船一号（Chandrayaan-1）搭载的月球矿物绘图仪（Moon Mineralogy Mapper, M³）是由美国国家航空航天局（NASA）支持的成像光谱仪，它设置了全球模式（Global Mode）与目标模式（Target Mode）两种工作模式全球模式以 140m 空间分辨率、86 个光谱通道获取全月球基础光谱地图，覆盖范围广，在此模式下覆盖率可达到全月球 95%以上；目标模式以 70m 空间分辨率、260 个空间光谱通道（如图 1）对重点区域开展高精度探测，覆盖月表 25%~50%^[1]。M³ 仪器的观测周期长，且可以获取 420~3000nm 的连续光谱数据，在该波段范围内覆盖了月表多种矿物如橄榄石、辉石、斜长石等月球关键矿物具有诊断意义的特征吸收带（如图 2），可以为这些关键矿物的识别和空间分布制图提供重要数据支撑^{[1][2]}。




图 1 M³ 数据在目标模式下的数据立方体^[1]




图 2 M³数据波长范围内的月球常见矿物光谱曲线^[2]

然而，由于月球矿物绘图仪的传感器是由推扫线性电荷耦合器件（CCD）阵列组成，每个 CCD 不同的光电特性会导致不同的光谱响应函数，导致对输入信号的响应不一致，因此数据质量受探测器固有特性影响较为显著^[3]，在 M³ 数据上主要体现为条带噪声的干扰（如图 3）。产生这种噪声的原因可归纳为两种：其一是线阵探测器各单元在光电响应、暗电流及灵敏度等方面的固有差异，导致基线偏移；其二是太空环境中的太阳风、高能粒子及电磁脉冲等突发干扰，易引发信号采集电路异常，进而造成行向噪声的剧烈波动，形成随机条带。此类干扰具有较强的随机性，常局限于特定行或波段，且与固有噪声叠加，显著加剧了条带效应，在月球极区等低光照区域表现尤为突出^[5]。M³ 数据上的噪声兼具了空间域和光谱域噪声^[6]，在空间域上表现为行向条纹，在光谱域上表现为光谱的失真如光谱锯齿及吸收峰畸变，整体而言，M³ 数据噪声呈现空间随机、光谱相关、强弱不均的复合分布特性，这些问题严重干扰矿物反演结果的可靠性。因此，研究适配 M³ 数据特性的高效去噪方法具有重要的科学意义与应用价值^[7]。




图 3 M³数据不同波段上的噪声 (a)Band 4; (b)Band 22; (c)Band 41; (d)Band 78

目前的高光谱数据的降噪方法可以大致分为四类，分别是统计匹配、数字滤波、变分模型和深度神经网络模型^[8]。其中，基于统计的方法因其实现简便，是遥感图像条带去除的经典方案，典型代表包括矩匹配法与直方图匹配法。这类方法仅利用图像自身的统计特性进行校正，在遥感影像地物分布均匀、遥感影像数据较多且具有统计意义时能够获得较好的处理效果^[9]，但其性能高度依赖预设的参考统计量^{[10]-[14]}。数字滤波方法通常是通过频域变换处理条带噪声，假设条带对应特定频率分量，采用傅里叶滤波^{[15][16]}。等滤波器以及小波变换^[17]来实现抑制。

变分模型的本质是通过构建包含数据保真项与先验正则项的能量泛函实现噪声去除，低秩恢复、稀疏表达都是常用的先验约束类型^{[18][19]}。其中 Zhao 等^[20]提出了一种利用低秩矩阵恢复和导向剖面的去除月球 M³ 高光谱图像噪声的 LRHP 方法，通过 Hodrick-Prescott 滤波对含条带图像的列均值曲线进行平滑处理得到引导轮廓，然后将其与低秩约束一起融入到正则化优化模型，采用交替方向乘法（ADMM）拆解为低秩中间图像求解与干净图像优化两

个子问题迭代求解,可在彻底去除密集嵌入式条带的同时,保留月球表面空间结构与矿物光谱特征。前面提到的几类模型驱动方法,大多为多种方法的相互融合,或是与深度学习模型的融合^[21]。

而近年来深度学习模型在高光谱图像去噪领域得到快速发展,以卷积神经网络(CNN)、Transformer、Mamba为代表的模型凭借强大的特征学习能力,在噪声抑制与细节保持方面均取得了优异性能。Guan等^[21]提出的DnRCNN,从高光谱图像波段内与波段间的相关性出发,设计选择性循环记忆单元提取空间噪声与光谱内容特征,通过循环融合策略互补特征,在去除条带噪声的同时有效保留光谱与空间细节;Hu等^[22]提出了HCANet,融合卷积与注意力机制,构建了兼顾局部光谱关联与长程依赖的混合架构,是CNN-Transformer混合去噪模型的代表性工作;Pan等^[24]提出的MAFNet采用渐进式多尺度自适应融合与协同注意力模块,实现了全局上下文建模与空间细节保留的协同优化;Fu等^[25]提出的SSUMamba将Mamba引入光谱去噪,通过整合空间-光谱连续扫描和双向Mamba来捕捉长距离空间-光谱的依赖关系;Zhu等^[26]提出的MUNet基于U型架构与Mamba上下文交互模块,以像素级输入最大化保留信息,进一步强化了全局与局部特征的融合表征;Duan等^[27]提出的LaMamba则通过线性注意力与3D选择性扫描机制,解决了传统Mamba长序列信息遗忘与光谱失真问题,实现了去噪性能与光谱保真度的同步提升。

上述方法多数是针对地球高光谱场景,通常依赖平稳噪声假设或显式先验。然而,月球高光谱数据通常由探测器在极端条件下获取,受成像距离远、空间环境干扰强及光照条件复杂等因素的影响,其噪声呈现出更强的不确定性及非平稳特性。且月球表面地物组成和分布相对单一,但有自身独特的空间光谱相关性,如矿物主导的光谱特性、区域空间聚集性^[28]等,导致传统方法重预设先验与实际数据的分布存在一些偏差,从而限制了其去噪性能。

相比之下,深度学习方法无需预设严格先验并具备强大的自适应特征学习能力,为处理月球高光谱数据提供了更有潜力的解决方案。但将其应用于月球高光谱去噪仍然面临月球数据样本稀缺、真实噪声难以模拟等问题,为此,本文基于这两点开展了研究。参考Mesariya等^[29]提到的先使用TVC滤波获取干净基准数据,再将含噪数据与伪标签配对去训练深度学习模型思路,本文选择了前文提到的LRHP模型对 M^3 数据进行处理得到伪干净样本数据,以此解决参考样本缺失问题。而针对月球真实噪声的泛化能力不足这个问题,本文使用高斯差分法等方法预先对 M^3 数据的1600个图像块进行噪声统计,提取高斯噪声强度、条带占比、条带强度及含噪波段占比等关键参数,构建与月球真实噪声特点高度一致的人工合成噪声,从而提升模型对真实噪声的适应与去除能力。

2 相关理论与方法

深度学习高光谱去噪模型本质上是一种数据驱动的端到端非线性映射学习方法,其目标是学习含噪图像与干净图像之间的映射关系。当前主流模型大多采用编码器-解码器(Encoder-Decoder)结构,整体流程通常包括初始特征嵌入、编码特征提取、特征解码与图像重建四个阶段,不同模型之间的差异主要体现在特征建模方式与上下文信息交互机制上。

在初始特征嵌入阶段,大多数模型采用卷积操作提取浅层空间-光谱特征,其中Hider^[30]、HCANet^[22]、SSUMamba^[25]与LAMamba^[27]采用3D卷积联合提取空间与光谱信息;MUNet^[26]、MAFNet^[24]与SST^[31]则主要采用2D卷积提取空间特征;AODN^[32]结合2D与1D卷积分别建模空间与光谱信息。部分Transformer模型如S²OTAN^[33]采用Patch线性嵌入方式,将输入划分为若干图像块后映射为特征向量;而DnRCNN^[21]等RNN类模型则将光谱维视为时序维度,通过递归卷积结构实现跨波段特征传播。

编码器阶段是网络的核心部分，其通过层级压缩与特征提纯实现噪声与有效信号的分离，并通常引入残差连接以缓解深层网络中的梯度消失与信息退化问题。CNN 类模型如 MAFNet^[24]通过多尺度卷积与特征融合增强局部纹理表达能力；Transformer 类模型如 HCANet^[22]与 SST^[31]利用自注意力机制实现全局上下文建模；Mamba 类模型如 SSUMamba^[25]与 LAMamba^[27]则基于状态空间模型（SSM）对空间与光谱维度进行序列化扫描，实现长程依赖关系的高效建模。此外，编码器与解码器之间通常还包含瓶颈层（Bottleneck Layer），用于进一步增强深层全局特征表达能力。

解码器阶段主要负责逐步恢复空间分辨率与空谱细节信息，大多数模型采用与编码器近似对称的多层级结构，并通过编码器-解码器间的跳跃连接（Skip Connection）传递浅层细节特征，以缓解下采样导致的信息损失并保持光谱连续性。由于高光谱图像需要尽可能保留完整光谱信息，因此多数模型仅在空间维度进行上下采样操作。部分模型还采用非对称结构，例如 LAMamba^[27]采用 6 层编码器与 5 层解码器组成的 11 层 U 型网络，以在降低模型复杂度的同时增强深层特征建模能力。

在最终重建阶段，当前主流模型普遍采用残差学习（Residual Learning）策略完成图像恢复。一类方法通过预测噪声残差并从含噪图像中扣除噪声实现重建，如 Hider^[30]、HCANet^[22]与 MUNet^[26]；另一类方法则直接重建干净图像，并在网络末端引入全局残差连接（Global Residual Connection）融合浅层输入与深层特征，代表模型包括 SSUMamba^[25]与 LAMamba^[27]，其通常具有更好的全局恢复能力。

主流深度学习模型高光谱数据去噪框架




图 4 主流深度学习模型高光谱数据去噪框架

2.2 噪声模型主要参数定义

假设在 M^3 数据上的所有条纹噪声均可以被视为加性噪声，那么高光谱影像的退化模型可以表示为：

$$Y = X + N \quad (2.1)$$

其中：Y 代表含噪观测高光谱数据；X 代表真实干净的高光谱数据；N 代表噪声。 M^3 数据的主要噪声为高斯噪声与条带噪声，所以后面我们用高斯噪声与条带噪声的参数来构建噪声模型。参数定义与计算方式如下。

2.2.1 高斯噪声强度

采用高斯差分法估计各波段高斯噪声强度。对第 λ 各波段 I_λ 进行高斯低通滤波得到平滑分量，这里的*代表卷积：

$$I_{low,\lambda} = G_1 * I_\lambda \quad (2.2)$$

而噪声分量就是原图与平滑图之差：

$$n_\lambda = I_\lambda - I_{low,\lambda} \quad (2.3)$$

该波段的噪声标准差为：

$$\sigma_\lambda = \sqrt{\frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W (n_\lambda(i,j) - \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W n_\lambda(i,j))^2} \quad (2.4)$$

2.2.2 条带列占比

通过列均值突变检测条带区域。第 λ 波段第 j 列均值为：

$$\mu_{\lambda, j} = \frac{1}{H} \sum_{i=1}^H I_\lambda(i, j) \quad (2.5)$$

第 λ 波段全局列均值与标准差为：

$$\bar{\mu}_\lambda = \frac{1}{W} \sum_j \mu_{\lambda, j} \quad (2.6)$$

$$\sigma_{\mu,\lambda} = \sqrt{\frac{1}{W-1} \sum_{j=1}^W (\mu_{\lambda,j} - \bar{\mu}_\lambda)^2} \quad (2.7)$$

满足 $|\mu_{\lambda, j} - \bar{\mu}_\lambda| > 1.2\sigma_{\mu,\lambda}$ 的列为条带列：

$$S_\lambda = \{j \in \{1, 2, \dots, W\} | |\mu_{\lambda, j} - \bar{\mu}_\lambda| > 1.2\sigma_{\mu,\lambda}\} \quad (2.8)$$

其中 S_λ 为第 λ 波段的条带列下标集合， $|S_\lambda|$ 表示集合中元素的个数（及条带列数）。

第 λ 波段的条带列占比为：

$$r_\lambda = \frac{|S_\lambda|}{W} \quad (2.9)$$

2.2.3 条带强度

条带强度表示条带列与正常区域的平均偏差幅度：

$$s_{\lambda} = \frac{1}{|S_{\lambda}|} \sum_{j \in S_{\lambda}} |\mu_{\lambda,j} - \bar{\mu}_{\lambda}| \quad (2.10)$$

其中 S_{λ} 是条带列索引集合。

2.2.4 含噪波段占比

条带列占比大于 5%的波段被视作含噪波段。

$$R_B = \frac{1}{C} \sum_{\lambda=1}^C \mathbb{I}(r_{\lambda} > 0.05) \quad (2.11)$$

其中 $\mathbb{I}(\cdot)$ 表示指示函数，条件成立时为 1，否则为 0；C 为总波段数。

2.3 实验评估指标

2.3.1 传统模型实验评估指标

由于真实实验中没有用于参考的真实影像，所以参考 Zhao 等^[19]的文章，选择无参考的 MICV 指标对实验结果进行定量评估，MICV 的表达式如下：

$$\text{MICV} = \frac{1}{B} \sum_{i=1}^B \frac{R_{m_i}}{R_{s_i}} \quad (2.12)$$

其中 R_{m_i} 和 R_{s_i} 分别代表所选择的影像区域第 i 个波段的均值与标准差，MICV 的值越高，代表恢复结果中残留的条带噪声越少，模型所获得的恢复结果质量越高，本文选择的评估区域大小为 10×10，分别选择了四个角和中心的五个区域做均值得到的评估结果。

2.3.2 深度学习模型实验指标

在深度学习模型的结果评估中，本文采用 Fu 等^[25]和 Duan 等^[27]中提到的深度学习指标 CLPIQA+^[34]、TOPIQ-NR^[35]和 QualiCLIP^[36]这三个无参考指标开展定量评价。由于上述指标仅适用于 RGB 三通道图像与灰度图像，因此需要对高光谱数据进行波段合成。参考孙灵芝等^[37]的研究结论，月球铁镁质矿物的特征吸收峰主要集中于 1000 nm 与 2000 nm 附近。为直观表征月表矿物的空间分布规律，本文选取 M³ 数据中对应特征波段的 Band 22(1009.95nm): Band 61(2018.02):Band 47(1508.99nm)=R:G:B 进行 RGB 假彩色合成。在该组合下，不同矿物呈现出清晰的色调差异：斜长岩因三波段反射率均偏高，表现为浅绿至黄绿色；橄榄石因 1000 nm 吸收谷和 2000 nm 高反射，呈现橙红色；辉石类矿物因 1000 nm 与 2000 nm 的双吸收谷，多呈蓝紫色调；成熟月壤则因反射率整体偏低且光谱特征平缓，表现为灰或棕褐色。基于上述岩性与颜色的对应关系，本文进一步开展无参考指标计算与去噪效果的视觉分析。

其中，CLPIQA+方法是基于 CLIP 模型的视觉-语言先验。它通过构建反义词提示对，实现了零样本条件下的画质与审美评估；TOPIQ-NR 是针对 HSI 量身定制，通过分析光谱-空间熵特征来衡量感知质量，无需使用地面真实图像；QualiCLI 同样基于 CLIP 架构，将劣化图

像与质量导向的文本提示结合，推断语义层面的图像质量，相较 CLIPQA + 优化了质量感知表征能力。这三个指标都是得分越高，去噪效果越好。

同时，为定量评估各算法的光谱保真能力与全局重建误差，本文以伪干净参考数据为基准，引入光谱角 SAM 与全局相对误差 ERGAS 两项指标开展量化分析。

SAM (Spectral Angle Mapper) 是光谱角，计算两个光谱向量的夹角。SAM 越小，代表光谱越相似，质量越好。

$$\text{SAM}(x, y) = \arccos \left(\frac{\langle x, y \rangle}{\|x\|_2 \cdot \|y\|_2} \right) \quad (2.13)$$

其中 x, y 是两个图像的 N 个波段对应像元的光谱向量，一般 x 代表的是参考图像， y 是测试图像。

ERGAS (Relative Dimensionless Global Error in Synthesis) 是全局相对无量纲综合误差。ERGAS 越小，代表整体的相对误差越小，图像恢复的质量越好。

$$\text{ERGAS} = \frac{100}{r} \sqrt{\frac{1}{N} \sum_{k=1}^N \left(\frac{\text{RMSE}_k}{\mu_k} \right)^2} \quad (2.14)$$

其中 r 代表空间分辨率的比值，本研究设定的为 1； N 为波段总数； RMSE_k 为第 k 个波段的均方误差； μ_k 为参考图像第 k 个波段的均值。

为了综合评估噪声模型的去噪的综合能力，本文采用了加权的方法对以下的五个指标进行了加权计算来获得更综合的评价。加权的公式为：

$$\begin{aligned} \text{Score} = & 0.15 \times \text{CLIPQA} + 0.15 \times \text{TOPIQNR} \\ & + 0.25 \times \text{QualiClip} + 0.25 \times \text{SAM}_n + 0.2 \times \text{ERGAS}_n \end{aligned} \quad (2.15)$$

其中 SAM_n 是 SAM 进行归一化处理之后的结果，越大代表光谱保真度越好； ERGAS_n 是 ERGAS 进行归一化处理之后的结果，数值越大代表全局误差越小。本文提高了 QualiCLIP 和 SAM_n 的比重。前者可以更精准地反映伪彩色图像的视觉细节质量，后者则强化了对光谱畸变的约束，确保去噪过程中矿物光谱特征不被破坏。归一化全局误差 (ERGAS_n) 与通用无参考指标 (CLIPQA、TOPIQ-NR) 则作为辅助项，共同构成兼顾视觉效果与光谱保真的评价体系。

3 实验和结果

3.1 数据预处理

因为高光谱降噪深度学习模型的输入数据集一般是干净-含噪数据集，而月球 M^3 数据没有完全干净的数据，所以本研究使用传统的降噪模型来做一个伪干净数据集。我们选择了目前比较主流的三种传统模型，分别是 NMoG^[38]、LRTD^[10]和 LRHP^[19]这三种传统模型。其中，NMoG 通过波段自适应高斯混合建模与贝叶斯低秩分解处理非独立同分布噪声；LRTD 基于张量分解与全变分正则化分离条带并保留细节；LRHP 借助 HP 滤波引导轮廓与低秩约束实现高效去条带。

为进一步验证模型的去噪效果，本文引入无参考图像质量评价指标 MICV 对实验结果开展定量评估。同时，为检验各模型在不同噪声强度下的去噪鲁棒性，本文选取三组噪声水平各异的月球 M^3 数据进行对比测试。实验所用三组月球 M^3 测试数据集，均引自 Zhao 等人在

GitHub 平台公开的实验数据。

随后，本文依据模型相关文献推荐的参数配置与训练迭代轮次，对三种传统去噪模型开展对照实验。所有对比实验均在统一环境下完成，硬件平台为 Intel Core i5-12500H 处理器，软件环境为 MATLAB R2023b。

结合目视评价（如图 5）与定量指标分析（如表 1）可得，LRHP 去噪性能最优，尤其在强噪声条件下可彻底去除条带干扰，且 MICV 指标在三组实验中均达到最优，同时计算效率最高，适合大批量数据处理。NMoG 在稀疏噪声场景效果较好，但噪声强度增大后去噪能力明显下降，条带残留明显，且运算耗时较长。LRTD 的去噪效果与计算效率均处于中等水平，在强噪声场景下恢复效果较差。值得注意的是，LRHP 处理结果在 RGB 合成时出现色彩失真，因此本文进一步通过光谱曲线分析其产生原因。

表 1 各噪声等级下各模型指标

实验区域	评价指标	original	NMoG	LRTD	LRHP
尼科撞击坑 (稀疏噪声)	MICV	33.6543	34.958	35.9654	43.2055
	运行时间 /s	—	246.54	140.13	25.03
芬森撞击坑 (中等噪声)	MICV	25.0575	26.2314	27.4381	30.1326
	运行时间 /s	—	337.58	65.16	20.72
雨海 (密集噪声)	MICV	20.9694	26.0281	31.1902	35.746
	运行时间 /s	—	150.76	79.49	26.62




图 5 各噪声等级下各模型处理结果：(a)(e)(i)原始图像；(b)(f)(j)NMoG 处理结果；(c)(g)(k)LRTD 处理结果；(d)(h)(l)LRHP 处理结果；(a)-(d)尼科撞击坑（稀疏噪声）；(e)-(h)芬森撞击坑（中等噪声）；(i)-(l)雨海（密集噪声）

图 6 展示了各模型在 (100, 100) 像素处的原始光谱曲线与包络线去除后的光谱曲线结

果。在原始反射率光谱（图 6 (a)）中，各模型处理后的光谱曲线高度重合，难以直观区分模型间的保真度差异；而包络线去除后的光谱（图 6 (b)）有效凸显了吸收与反射特征，因此本文采用图 6 (b)的曲线对各模型的光谱保真性能进行评估。

由包络线去除后的光谱曲线可见，三种传统方法中，LRHP 模型的光谱平滑能力最强，能够有效抑制光谱锯齿噪声，但过度平滑导致光谱整体形态发生明显畸变与偏移，这也是 RGB 假彩色合成图像出现色彩偏差的主要原因。LRTD 模型的去噪效果较差，不仅未能有效消除原始光谱的锯齿波动，还在 500~1000 nm 波段引入了额外的光谱畸变。在光谱还原一致性上，NMoG 与原始光谱曲线贴合程度更高，光谱保真效果最优。




图 6 不同噪声情况下，在像素点(100,100)处：(a)(b)(c)为原始光谱曲线，(d)(e)(f)为去除包络线后的光谱曲线

但是综合目视去噪效果、定量指标与计算效率，本研究最终选取 LRHP 用于原始数据的批量去噪以生成伪干净数据集。

随后，本文采用 LRHP 模型对 1600 个尺寸为 300×300×83 的数据块进行批量去噪，并逐波段、逐光谱曲线进行人工筛选，剔除存在伪影、黑边、分块、去噪失效及图像偏移等问题样本（如图 7 所示），最终得到 432 个高质量的 300×300×83 伪干净数据块。数据集包含 2008 年与 2009 年两个年份的观测数据，引入多年观测样本可覆盖传感器老化等因素带来的差异，有助于提升后续深度学习模型的泛化能力与鲁棒性。




图 7 不符合要求数据(a)伪影；(b)RGB 光谱组合分块；(c)有分割位移

3.2 伪干净-合成噪声数据集构建

基于 2.2 节构建的噪声模型参数定义方法，本研究首先对 1600 个尺寸为 $300 \times 300 \times 83$ 的 M^3 原始数据块进行噪声参数的区间估计，分别获取的高斯噪声强度、条带列占比、条带强度及含噪波段占比，以此刻画真实数据中噪声的统计分布特征。

为了后续合成更具多样性与代表性的含噪样本，从而增强模型在不同噪声强度下的泛化能力，本研究在实测噪声参数的统计分布基础上，对参数范围进行了适度的扩充（如表 4）。含噪样本的逐样本生成在该参数区间内随机采样，具体加噪步骤如下：

- ① 根据采样得到的波段受影响比例，随机选择若干波段施加条带噪声；
- ② 在每个受影响波段内，依据采样的条带列比例随机选取若干列，并沿图像高度方向生成幅值服从均匀分布的条带扰动，列内所有像素值相同，形成条带结构；
- ③ 最后叠加区间内随机强度的零均值高斯噪声以模拟传感器随机误差。

最终含噪图像可表示为伪干净图像与两类噪声的线性叠加模型：

$$Y = S + G + X \tag{3.1}$$

其中 X 为伪干净图像， S 为条带噪声， G 为像素级高斯噪声。以上生成的 (X, Y) 对被用作伪干净-合成噪声数据集。

表 2 各噪声参数范围

噪声参数	取值范围	合成噪声范围
Sigma	[0.00,12.9]	[0.00,17.00]
Ratio_columns	[0.00,0.40]	[0.01,0.45]
Ratio_bands	[0.94,1.00]	[0.89,1.00]
Stripe_intensity	[0.01,0.67]	[0.01,1.00]

3.3 深度学习模型的训练与结果

本文基于前述构建的伪干净-含噪数据集，训练了五种深度学习模型，分别为 MAFNet^[22]、HCANet^[24]、SSUMamba^[25]、MUNet^[26]与 LAMamba^[27]。训练参数设置如下：MAFNet 与 HCANet 迭代 100 轮，SSUmamba 与 MUNet 迭代 35 轮，LAMamba 迭代 25 轮。所有模型均采用 PyTorch 深度学习框架，并在 NVIDIA RTX 4090 GPU 上进行训练。完成训练后，对各模型在三组不同噪声条件下的月球数据进行了推理比较。

在稀疏噪声条件下，各模型均表现出良好的去噪性能。其中，LAMamba 取得最优综合评分 Score，在空间细节恢复与光谱保真度上达到最佳平衡，同时目视结果显示其 RGB 假彩色合成图像与原始图像色彩一致性最高。在深度学习模型中，MAFNet 与 HCANet 兼具较强去噪能力与较高计算效率，但二者的 RGB 假彩色合成图像出现明显色彩偏移，如图 8(e)(f) 所示，标注框中辉石类矿物对应的紫色区域与其他地物的颜色发生混叠，原绿色特征的斜长石区域变为紫褐色与矿物混淆，不利于目视解译与矿物区分。MUNet 噪声去除较为彻底，但色彩失真最为严重，全局光谱误差指标 ERGAS 最高。SSUMamba 存在少量条纹残留，但未出现噪声引起的异常彩色伪影，推测其将部分条纹结构作为空间纹理特征学习并保留，同时该模型 SAM 与全局误差较高，因此综合评分最低。传统模型中，NMoG 模型在稀疏噪声下的表现最好。

表 3 尼科撞击坑（稀疏噪声情况）去噪后结果对比

NMoG	LRTD	LRHP	MAFNet	HCANet	SSUMamba	MUNet	LAMamba
------	------	------	--------	--------	----------	-------	---------

	[38]	[10]	[19]	[22]	[24]	[25]	[26]	[27]
CLIPQA $\uparrow$	0.3574	0.4029	0.3503	0.3103	0.3426	0.3336	0.3424	0.3532
TOPIQ-NR $\uparrow$	0.1733	0.1949	0.1851	0.1840	0.1791	0.1847	0.3708	0.1933
QualiCLIP $\uparrow$	0.3877	0.3514	0.4112	0.3020	0.3743	0.4210	0.3708	0.4346
SAM $\downarrow$	0.0068	0.0169	0.0086	0.0067	0.0064	0.0199	0.0118	0.0070
ERGAS $\downarrow$	5.5759	11.8850	14.9572	4.5190	4.7591	15.7058	16.7593	5.4908
Score $\uparrow$	0.4601	0.2732	0.3474	0.4475	0.4708	0.1830	0.2747	0.4869
Times(train)	/	/	/	24	154	1211	1486	3665
Times(test)	246.54	140.13	25.03	5.10	8.47	7.72	28.05	9.40




图 8 尼科撞击坑（稀疏噪声情况）去噪后结果对比

(Band=22:Band=61:Band=47=R:G:B)(a)noisy; (b)NMoG; (c)LRTD; (d)LRHP; (e)MAFNet; (f)HCANet; (g)SSUmamba; (h)MUNet; (i)LAMamba

从光谱曲线结果（如图 9）来看，NMoG、MAFNet、LAMamba 及 SSUmamba 模型的光谱曲线与原始光谱高度吻合，1500~2000 nm 吸收谷的深度、位置及两侧上升趋势均得到了还原，同时光谱的锯齿状波动也得到了有效平滑；HCANet、MUNet 与 LRTD 模型的曲线整体趋势与原始光谱相近，但仍保留了较为明显的噪声波动；LRHP 模型的曲线则与原始光谱差异较大，整体形态过度平滑。




图 9 稀疏噪声情况下各模型处理结果在像素(100, 100)处: (a)光谱曲线; (b)去除包络线后光谱曲线

总体而言，稀疏噪声场景下深度学习模型与传统模型性能差距较小，但可以看到 MAFNet、HCANet 以及 LAMamba 的综合效果优于传统方法，且超越了用于生成伪干净数据的 LRHP

模型。这表明尽管深度学习模型以伪干净数据为参考基准进行训练，但其学习与重构能力可以超越参考数据，充分验证了深度学习方法在特征提取与噪声建模上的强大能力。

在中等噪声条件下，不同模型的去噪性能开始呈现出差异。LAMamba 依旧取得最优综合评分，并在光谱保真度上达到最优指标。在这个场景下，MAFNet、HCANet 与 MUNet 在中等噪声下出现不同程度的边缘模糊现象，而 SSUMamba 与 LAMamba 能够更好地保持地物边缘结构与空间纹理清晰度。在此噪声强度下，除 MUNet 外，其余深度学习模型的综合去噪效果都显著优于传统去噪方法。

表 4 芬森撞击坑（中等噪声情况）去噪后结果对比

	NMoG [38]	LRTD [10]	LRHP [19]	MAFNet [22]	HCANet [24]	SSUMamba [25]	MUNet [26]	LAMamba [27]
CLIPQA+↑	0.3735	0.3589	0.4059	0.3762	0.3791	0.3747	0.3748	0.3604
TOPIQ-NR↑	0.1819	0.1959	0.2109	0.2067	0.2037	0.1993	0.2062	0.2088
QualiCLIP↑	0.4137	0.3648	0.4533	0.4096	0.4257	0.3936	0.4366	0.3983
SAM↓	0.0125	0.0120	0.0109	0.0085	0.0082	0.0086	0.0135	0.0060
ERGAS↓	31.6458	8.6647	19.7761	8.7781	9.7050	11.8257	11.5893	9.0446
Score↑	0.2116	0.3523	0.3429	0.4371	0.4406	0.4097	0.3274	0.4783
Times(train)	/	/	/	24	154	1211	1486	3665
Times(test)	337.58	65.16	20.72	5.05	8.96	7.67	27.77	9.23




图 10 芬森撞击坑去噪后结果对比(Band=22:Band=61:Band=47=R:G:B)(a)noisy; (b)NMoG; (c)LRTD; (d)LRHP; (e)MAFNet; (f)HCANet; (g)SSUmamba; (h)MUNet; (i)LAMamba




图 11 中等噪声情况下各模型处理结果在像素(100, 100)处: (a)光谱曲线; (b)去除包络线后光谱曲线

在密集噪声场景下，LAMamba 依旧取得最优综合评分。其中 MUNet 在 TOPIQ-NR 指标上表现最优，目视结果显示其噪声去除最为彻底，其余模型均存在少量条带残留，但 MUNet 在光谱保真度方面仍存在明显缺陷，可以看到其光谱曲线上仍然存在明显的光谱锯齿，且与原始光谱曲线的形态有着较大差异（如图 13(b)）。此外，原始图像受光照影响在撞击坑的边缘产生了一些彩色的伪影（如图 12 中标注），LRHP、MAFNet、HCANet 及 MUNet 均将这种伪影进行了去除，而 SSUMamba 与 LAMamba 则保留了这一原始特征，复原结果更贴近真实观测。在该噪声强度下，除 MUNet 外，其余深度学习模型的去噪效果均优于传统模型。同时可观察到，随着噪声强度提升，LRHP 与 SSUMamba 的优势开始逐步显现。

表 5 雨海（密集噪声情况）去噪后结果对比

	NMoG [38]	LRTD [10]	LRHP [19]	MAFNet [22]	HCANet [24]	SSUMamba [25]	MUNet [26]	LAMamba [27]
CLIPQA↑	0.5161	0.5321	0.5345	0.5579	0.5687	0.5655	0.5281	0.5693
TOPIQ-NR↑	0.2461	0.2339	0.2512	0.2348	0.2356	0.2381	0.2573	0.2386
QualiCLIP↑	0.4879	0.4923	0.4861	0.5067	0.5268	0.4938	0.4653	0.5009
SAM↓	0.0610	0.0170	0.0198	0.0117	0.0101	0.0110	0.0207	0.0086
ERGAS↓	42.8415	19.5742	13.8271	13.4681	17.9650	6.4104	38.8349	7.7961
Score↑	0.2363	0.5267	0.5436	0.5848	0.5772	0.6188	0.4179	0.6247
Times(train)	/	/	/	24	154	1211	1486	3665
Times(test)	150.76	79.49	26.62	5.27	9.93	7.68	26.91	9.49




图 12 雨海去噪后结果对比(Band=22:Band=61:Band=47=R:G:B)(a)noisy; (b)NMoG; (c)LRTD; (d)LRHP; (e)MAFNet; (f)HCANet; (g)SSUmamba; (h)MUNet; (i)LAMamba




图 13 密集噪声情况下各模型处理结果在像素(100, 100)处: (a)光谱曲线; (b)去除包络线后光谱曲线

Zhao 等研究表明,干净月球高光谱影像与受条带噪声污染影像的列均值曲线具有一致的整体变化趋势,但抖动程度差异显著。条带噪声会导致列均值曲线产生明显振荡,而真实地物信号对应的列均值分布则相对平稳。基于这一特性,重建结果的列均值平滑程度以及与原含噪影像列均值趋势的一致性,可作为评价去噪效果与光谱保真能力的重要依据^[19]。从列均值曲线(如图 14)可以看出,不同方法在噪声抑制与结构保持之间存在明显差异。LRHP 由于引入列均值稳定约束,其曲线最为平滑,说明其对条带噪声的抑制能力最强。然而,其结果相较于原始列均值趋势出现一定偏离,表现为过度平滑,导致部分真实结构未能有效保留;NMoG 与 LRTD 在趋势一致性方面表现较好,能够较好跟随原始列均值变化,但其曲线中仍存在明显高频波动,说明仍保留一定程度的条带噪声。

在深度学习方法中,SSUmamba 与 LAMamba 在趋势一致性与结构保持方面表现较优,其列均值曲线与原始曲线具有较高的贴合度。但同时仍可观察到一定程度的波动,表明条带噪声未被完全去除。

相比之下,MAFNet 与 HCANet 具有较好的平滑效果,而 MUNet 的平滑程度最强,表现出最彻底的噪声抑制能力。然而,这类方法在一定程度上偏离原始列均值趋势,说明其在去噪过程中引入了结构失真,从而可能导致一定的光谱或辐射信息偏差。




图 14 各模型去噪结果与原始含噪图像在第 22 波段的列均值曲线对比(a)NMoG; (b)LRTD; (c)LRHP; (d)MAFNet; (e)HCANet; (f)SSUmamba; (g)MUNet; (h)LAMamba

3.4 合成噪声模型有效性验证

本文构建的噪声模型如 2.2 节及 3.2 节所示,现有主流深度学习模型采用的高斯-条带混合噪声(Case2)通常为:全波段加随机强度高斯噪声($\sigma \in [30,70]$),再随机选约 1/3 的波段,在这些波段里随机污染 5%~15%的列来作为条带^{[22]-[27]}。

为验证本文构建的条纹-高斯混合噪声模型在月球高光谱场景下的有效性与可靠性,本文设计对照实验,将其与上述标准 Case2 噪声参数进行对比。考虑到 MAFNet 在同类方法中具备最优的计算效率,实验保持 MAFNet 网络结构和训练轮数不变,分别基于两种噪声模型生成训练数据并完成模型训练,进而从视觉效果与定量评价指标两方面开展对比分析。

实验结果表明(如图 15),采用 Case2 噪声参数训练得到的结果存在明显的过度平滑与

模糊现象，且综合评价指标 Score 在三种噪声情况下都低于本文噪声模型训练所得结果。这充分说明，本文构建的混合噪声模型更贴近真实高光谱数据的噪声分布，在月球场景下具有更高的真实性与适用性。

表 7 各噪声情况下不同噪声模型训练结果

实验区域	噪声模型	CLIPQA	TOPIQ-NR	QualiCLIP	SAM	ERGAS	Score
尼科撞击坑	Case2	0.3248	0.1516	0.2319	0.0078	7.0456	0.3971
(稀疏噪声)	stripes	0.3103	0.1840	0.3020	0.0067	4.519	0.4475
芬森撞击坑	Case2	0.3448	0.1911	0.2888	0.0085	8.0246	0.3944
(中等噪声)	stripes	0.3762	0.2067	0.4096	0.0084	8.7781	0.4371
雨海	Case2	0.4432	0.2209	0.3365	0.0105	7.5393	0.5556
(密集噪声)	stripes	0.5579	0.2348	0.5067	0.0117	13.4681	0.5848




图 15 不同噪声模型下的去噪效果对比。(a)(b)(c) 伪干净数据-本文合成噪声数据集训练模型的去噪结果；(d)(e)(f) 伪干净数据-文献 case2 情况下合成噪声数据集训练模型的去噪结果

4 结论

针对月球矿物绘图仪（M³）高光谱数据中噪声类型复杂、传统去噪方法效果受限的问题，本文将深度学习去噪模型迁移至月球高光谱场景。研究工作围绕噪声建模、伪噪声数据集构建及多模型去噪对比三个部分展开，完成了面向 M³数据的去噪方案构建与性能验证。

基于月球 M³实测高光谱数据的噪声统计分析，本研究根据数据的真实噪声特征，构建了适配月球高光谱场景的混合噪声模型。并通过多种传统去噪方法的对比试验，选出综合效果与效率最优的 LRHP 算法批量处理并筛选得到高质量的伪干净样本集，完成深度学习数据集的搭建。

接着我们使用该深度学习数据集进行了不同深度学习模型的对比实验。对比实验结果表明，LAMamba 在去噪效果与光谱保真度方面综合性能最优；MAFNet 具备突出的计算效率；HCANet 目视去噪表现良好，但与 MAFNet 一致，均存在矿物色彩偏移问题；SSUMamba 条带残留抑制能力有限，MUNet 则在光谱细节保留与光谱锯齿去除方面存在明显短板。

针对 MAFNet、HCANet 及 MUNet 普遍出现的色彩偏移现象，推测其与伪干净数据集的构建质量相关。本研究是基于 LRHP 模型生成伪干净样本，而该方法本身存在光谱过度平滑与局部色彩失真的缺陷。由此说明，上述三类模型对参考真值的依赖程度较高，复原效果

易受伪干净数据质量限制。因此,若需进一步优化模型性能,后续需重点改进伪干净数据集的构建策略。相比之下,SSUMamba与LAMamba对监督参考数据的依赖性更低,模型能够更多地学习原始高光谱数据的自身特征,在复原过程中更好地保留原始图像的色彩与光谱信息,还原效果更贴合真实观测数据。

此外,实验结果也表明,深度学习模型能够在伪干净样本的基础上,进一步挖掘空间-光谱特征,实现比传统方法更优的去噪效果。同时,对照试验验证了本文噪声模型相比现有固定参数噪声方案更贴合M³数据的真实噪声特点,提高了模型在月球场景下的去噪能力。

研究结果可有效改善月球高光谱影像质量,为后续月球地质研究提供可靠的数据支撑。后续将采用综合性能最优的LAMamba模型,对大范围M³影像开展去噪处理,进一步用于月表矿物反演与地质特征分析。

参考文献

- [1] C. Pieters, J. Boardman, B. Buratti, A. Chatterjee, R. Clark, T. Glavich, R. Green, J. Head, P. Isaacson, E. Malaret, T. Mccord, and J. Mustard, "The Moon Mineralogy Mapper (M3) on Chandrayaan-1," *Current Science*, vol. 96, 2008.
- [2] V. Bernhardt, A. Grumpe, and C. Wöhler, "Spectral unmixing based construction of lunar mineral abundance maps," *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. XLII-3/W1, pp. 7 – 14, 2017.
- [3] R. O. Green et al., "The Moon Mineralogy Mapper (M³) imaging spectrometer for lunar science," *Journal of Geophysical Research*, vol. 116, p. E00G19, 2011.
- [4] J. Jia et al., "Destriping algorithms based on statistics and spatial filtering for visible-to-thermal infrared pushbroom hyperspectral imagery," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 57, no. 6, pp. 4077 – 4091, Jun. 2019.
- [5] 赵书珩.月球高光谱遥感影像复杂条带噪声处理的低秩方法研究[D].武汉大学,2021.
- [6] 杨辰, 月球矿源绘图仪(M3)数据预处理方法研究及应用[D]. 北京: 中国地质大学(北京), 2016.
- [7] 孙旖繁,甄治钧,陈圣波,等.基于地形校正后的月球矿物绘图仪数据的矿物丰度反演方法及其在 Apollo 着陆区的应用[J].*矿物学报*,2025,45(06):1106-1114.
- [8] Y. Chang, M. Chen, L. Yan, X.-L. Zhao, Y. Li, and S. Zhong, "Toward universal stripe removal via wavelet-based deep convolutional neural network," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 58, no. 4, pp. 2880 – 2897, 2020.
- [9] 白玉川,徐锐,李宗睿,等.基于间隔采样的快速变分条带噪声检测方法[J].*自然资源遥感*,2023,35(03):71-79.
- [10] Y. Chen, T.-Z. Huang, and X.-L. Zhao, "Destriping of multispectral remote sensing image using low-rank tensor decomposition," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 11, no. 12, pp. 4950 – 4967, Dec. 2018.
- [11] F. Gadallah, F. Csillag, and E. Smith, "Destriping multisensor imagery with moment matching," *International Journal of Remote Sensing*, vol. 21, no. 12, pp. 2505 – 2511, 2000.

- [12] L. Sun, R. Neville, K. Staenz, and H. P. White, "Automatic destriping of Hyperion imagery based on spectral moment matching," *Canadian Journal of Remote Sensing*, vol. 34, no. S1, pp. S68 – S81, 2008.
- [13] M. Wegener, "Destriping multiple sensor imagery by improved histogram matching," *International Journal of Remote Sensing*, vol. 11, no. 5, pp. 859 – 875, 1990.
- [14] B. Cao, Y. Du, D. Xu, H. Li, and Q. Liu, "An improved histogram matching algorithm for the removal of striping noise in optical remote sensing imagery," *Optik*, vol. 126, no. 23, pp. 4723 – 4730, 2015.
- [15] Q. Zeng, H. Qin, X. Yan, and T. Yang, "Fourier domain anomaly detection and spectral fusion for stripe noise removal of TIR imagery," *Remote Sensing*, vol. 12, no. 22, p. 3714, 2020.
- [16] Y. Hong, P. Rao, Y. Zhou, Y. Zhang, "A weighted guided filtering-based multidomain fusion destriping method," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 17, pp. 9178 – 9193, 2024.
- [17] R. Pande-Chhetri and A. Abd-Elrahman, "De-striping hyperspectral imagery using wavelet transform and adaptive frequency domain filtering," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 66, no. 5, pp. 620 – 636, 2011.
- [18] H. Zhang, W. He, L. Zhang, H. Shen, and Q. Yuan, "Hyperspectral image restoration using low-rank matrix recovery," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 52, no. 8, pp. 4729 – 4743, 2014.
- [19] W. He, H. Zhang, H. Shen, and L. Zhang, "Hyperspectral image denoising using local low-rank matrix recovery and global spatial – spectral total variation," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 11, no. 3, pp. 713 – 729, 2018.
- [20] S. Zhao, Q. Yuan, J. Li, Y. Hu, X. Liu, and L. Zhang, "A fast and effective irregular stripe removal method for moon mineralogy mapper (M3)," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, pp. 1 – 14, 2022.
- [21] J. Ye, F. Xiong, J. Zhou, and Y. Qian, "Iterative low-rank network for hyperspectral image denoising," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 62, 2025.
- [22] J. Guan, R. Lai, H. Li, Y. Yang, and L. Gu, "DnRCNN: Deep recurrent convolutional neural network for HSI destriping," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 7, pp. 3255 – 3268, July 2023.
- [23] S. Hu, F. Gao, X. Zhou, J. Dong, and Q. Du, "Hybrid convolutional and attention network for hyperspectral image denoising," *IEEE Geoscience and Remote Sensing Letters*, vol. 21, pp. 1 – 5, 2024.
- [24] H. Pan, F. Gao, J. Dong, and Q. Du, "Multiscale adaptive fusion network for hyperspectral image denoising," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 16, pp. 3045 – 3059, 2023.
- [25] G. Fu, F. Xiong, J. Lu, and J. Zhou, "SSUMamba: Spatial-spectral selective state space model for hyperspectral image denoising," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 62, pp. 1 – 14, 2024.
- [26] Z. Zhu, Y. Chen, S. Zhang, G. Luo, and J. Zeng, "Mamba-based UNet for hyperspectral image denoising," *IEEE Signal Processing Letters*, vol. 32, pp. 1411 – 1415, 2025.
- [27] P. Duan, Y. Luo, X. Kang, and S. Li, "LaMamba: Linear attention Mamba for hyperspectral image denoising," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 63, pp. 1 – 13, 2025.

- [28] Q. Yuan, Q. Zhang, J. Li, H. Shen, and L. Zhang, "Hyperspectral image denoising employing a spatial – spectral deep residual convolutional neural network," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 57, no. 2, pp. 1205 – 1218, 2019.
- [29] U. Mesariya, A. Shah, A. Nair, T. Vyas, S. Desai, and S. Tanwar, "Denoising lunar hyperspectral images using CNN with skip connections," in *2024 IEEE Space, Aerospace and Defence Conference (SPACE)*, Bangalore, India: IEEE, 2024, pp. 398 – 401.
- [30] H. Chen, G. Yang, and H. Zhang, "Hider: A hyperspectral image denoising transformer with spatial – spectral constraints for hybrid noise removal," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 7, pp. 8797 – 8811, July 2024.
- [31] M. Li, Y. Fu, and Y. Zhang, "Spatial-spectral transformer for hyperspectral image denoising," in *Proceedings of the 37th AAAI Conference on Artificial Intelligence*, Washington, DC, USA: AAAI Press, 2023, vol. 37, no. 1, pp. 1368 – 1376.
- [32] Z. Kan, S. Li, M. Hou, L. Fang, and Y. Zhang, "Attention-based octave network for hyperspectral image denoising," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 15, pp. 1089 – 1102, 2022.
- [33] Z. Xiao, H. Qin, S. Yang, X. Yan, and H. Zhou, "Spatial – spectral oriented triple attention network for hyperspectral image denoising," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 62, pp. 1 – 17, 2024.
- [34] J. Wang, K. C. Chan, and C. C. Loy, "Exploring CLIP for assessing the look and feel of images," in *Proceedings of the 37th AAAI Conference on Artificial Intelligence*, Washington, DC, USA: AAAI Press, 2023, vol. 37, no. 2, pp. 2555 – 2563.
- [35] C. Chen et al., "TOPIQ: A top-down approach from semantics to distortions for image quality assessment," *IEEE Transactions on Image Processing*, vol. 33, pp. 2404 – 2418, 2024.
- [36] L. Agnolucci, L. Galteri, and M. Bertini, "Quality-aware image-text alignment for real-world image quality assessment," *arXiv:2403.11176*, 2024.
- [37] 孙灵芝, 凌宗成, 刘建忠. 月球东海盆地的矿物光谱特征及遥感探测[J]. *地学前缘*, 2014, 21(06):188-203.
- [38] Y. Chen, X. Cao, Q. Zhao, and Z. Xu, "Denoising hyperspectral image with non-i.i.d. noise structure," *IEEE Transactions on Cybernetics*, vol. 48, no. 3, pp. 1054 – 1066, 2017.